

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Санкт-Петербургский политехнический университет Петра Великого»
Физико-механический институт
**Высшая школа прикладной математики и вычислительной
физики**

Отчёт по лабораторной работе № 3

Боксплот Тьюки и анализ выбросов
по дисциплине «Математическая статистика»

Выполнил студент гр.
5030102/30202:
Шильдт Д.С.

Преподаватель:
Баженов А.Н.

Санкт-Петербург
2026

СОДЕРЖАНИЕ

1	Постановка задачи	3
2	Теоретическая часть	3
3	Реализация	4
3.1	Язык программирования и среда	4
3.2	Используемые библиотеки	4
3.3	Суть реализованных методов	4
4	Результаты	5
5	Обсуждение	8
6	Выводы	9
7	Список литературы	10
8	Приложение	10

1 Постановка задачи

Цели и задачи работы:

- Научиться применять боксплот Тьюки в обработке и анализе одномерных распределений.
- Проанализировать, как размер выборки влияет на долю отсеиваемых аномальных значений.

Задание: Для пяти исследуемых распределений (Нормальное $N(0, 1)$, Коши $C(0, 1)$, Лапласа $L(0, 1/\sqrt{2})$, Пуассона $P(5)$ и Равномерное $U(-\sqrt{3}, \sqrt{3})$) необходимо выполнить следующие шаги:

1. Сгенерировать выборки объемом $n \in \{20, 100\}$. Построить боксплот Тьюки.
2. Определить долю выбросов экспериментально: для каждого распределения сгенерировать 1000 выборок заданного объёма, вычислить среднюю долю выбросов.

Практическая доля выбросов в выборке считается как отношение количества выбросов к количеству всех элементов в выборке. В данной работе необходимо посчитать среднюю долю выбросов, сгенерировав выборку 1000 раз.

2 Теоретическая часть

Для графического анализа одномерных выборок и выявления аномальных значений применяется диаграмма боксплот Тьюки. Границами центрального прямоугольника выступают нижняя $z_{1/4}$ и верхняя $z_{3/4}$ выборочные квартили. Длина ящика соответствует интерквартильной широте $IQR = z_{3/4} - z_{1/4}$.

Левый и правый «усы» определяют границы нормального (неаномального) разброса данных и вычисляются по формулам:

$$X_1^r = z_{1/4} - 1.5 \cdot IQR \quad (1)$$

$$X_2^r = z_{3/4} + 1.5 \cdot IQR \quad (2)$$

Любой элемент выборки x_i , удовлетворяющий условию $x_i < X_1^r$ или $x_i > X_2^r$, классифицируется как выброс. Доля выбросов рассчитывается как отношение количества таких аномальных элементов к общему объему выборки n .

3 Реализация

3.1 Язык программирования и среда

- **Используемый язык:** Python 3.14.2
- **Используемая среда разработки:** Visual Studio Code

3.2 Используемые библиотеки

- **numpy** — использовалась для работы с массивами, вычисления квартилей и обработки результатов моделирования.
- **scipy** — использовалась для генерации выборок из теоретических распределений (`norm`, `cauchy`, `laplace`, `poisson`, `uniform`).
- **matplotlib** — использовалась для построения боксплотов Тьюки и столбчатой диаграммы средней доли выбросов.
- **pathlib** — использовалась для автоматического создания каталогов и сохранения итоговых графиков и CSV-файла.

3.3 Суть реализованных методов

- `getDistributionConfigs()` — формирует единый список конфигураций исследуемых распределений (название, идентификатор файла и функция-генератор выборки).
- `tukeyBounds(sample)` — вычисляет границы выбросов по правилу Тьюки X_1^r и X_2^r через выборочные квартили и интерквартильную широту IQR .

- `outlierShare(sample)` — определяет долю выбросов в одной выборке как отношение количества наблюдений за границами Тьюки к объему выборки.
- `meanOutlierShare(generator, sample_size, repeats, rng)` — анализирует серию из 1000 повторов генерации и вычисляет среднюю долю выбросов для каждого распределения и каждого объема выборки $n \in \{20, 100\}$.
- `saveBoxplotFigure(...)` — строит и сохраняет боксплоты Тьюки для объемов $n \in \{20, 100\}$.
- `saveOutlierShareFigure(rows)` — строит итоговую столбчатую диаграмму средних долей выбросов для всех распределений при двух объемах выборки.
- `saveOutlierCsv(rows)` и `printReport(rows)` — отвечают за экспорт и представление результатов.

4 Результаты

В ходе работы для каждого исследуемого распределения построены диаграммы Тьюки при объемах выборки $n \in \{20, 100\}$ (рис. 1–5). Дополнительно на рис. 6 показано сравнение средних долей выбросов по всем распределениям.

Экспериментально определенная средняя доля аномальных значений (выбросов), вычисленная по 1000 независимым повторениям генерации выборок, приведена в таблице 1.

Таблица 1: Средняя доля выбросов для исследуемых распределений

Распределение	Средняя доля выбросов, $n = 20$	Средняя доля выбросов, $n = 100$
$N(0, 1)$	0.0185	0.0096
$C(0, 1)$	0.1368	0.1520
$L(0, 1/\sqrt{2})$	0.0592	0.0623
$P(5)$	0.0185	0.0129
$U(-\sqrt{3}, \sqrt{3})$	0.0013	0.0000




Рис. 1: Боксплот Тьюки для нормального распределения $N(0, 1)$




Рис. 2: Боксплот Тьюки для распределения Коши $C(0, 1)$




Рис. 3: Боксплот Тьюки для распределения Лапласа $L(0, 1/\sqrt{2})$




Рис. 4: Боксплот Тьюки для распределения Пуассона $P(5)$




Рис. 5: Боксплот Тьюки для равномерного распределения $U(-\sqrt{3}, \sqrt{3})$




Рис. 6: Сравнение средних долей выбросов по правилу Тьюки

5 Обсуждение

Анализ эмпирических долей выбросов выявляет жесткую зависимость между формой хвостов распределения и количеством генерируемых аномалий.

Для равномерного распределения $U(-\sqrt{3}, \sqrt{3})$ с конечным носителем плотности появление значений за аналитическими границами усов Тьюки теоретически невозможно. Экспериментальные данные строго подтверждают этот факт: при $n = 100$ доля выбросов равна 0.000. Фиксация единичных аномалий на уровне 0.001 при $n = 20$ является вычислительным артефактом. Она вызвана случайным сужением выборочной интерквартильной широты IQR на микровыборках, а не свойствами самого закона распределения.

Распределения с экспоненциальным убыванием плотности вероятности (нормальное $N(0, 1)$ и дискретное Пуассона $P(5)$) характеризуются минимальной долей выбросов. При увеличении объема выборки до $n = 100$ эмпирическая доля аномалий для нормального закона составляет 0.010, для пуассоновского — 0.013. С ростом n оценка стабилизируется, нивелируя влияние случайных флуктуаций IQR .

Распределение Лапласа $L(0, 1/\sqrt{2})$ обладает более тяжелыми хвостами по сравнению с нормальным законом. Это обуславливает кратное увеличение числа аномальных наблюдений: эмпирическая доля выбросов составляет 0.059 при $n = 20$ и возрастает до 0.062 при $n = 100$.

Максимальное количество аномалий генерирует распределение Коши $C(0, 1)$ за счет степенного характера убывания плотности и отсутствия конечных теоретических моментов. Расчетная доля выбросов для данного закона достигает 0.152 (15.2%) при $n = 100$. Цифры доказывают недопустимость применения классических неробастных методов для обработки выборок Коши.

6 Выводы

В ходе работы исследовано влияние формы распределения и объема выборки на вероятность появления аномальных значений при графическом анализе одномерных данных боксплотом Тьюки.

Для законов с финитным носителем (Равномерное) генерация выбросов при достаточных объемах выборки исключена. Распределения с тяжелыми хвостами (Коши) систематически производят более 15% аномалий независимо от мощности выборки, что диктует необходимость применения

робастных статистических оценок при их исследовании.

Рост объема выборки от $n = 20$ до $n = 100$ обеспечивает стабилизацию выборочной интерквартильной широты IQR , за счет чего эмпирическая доля выбросов сходится к истинной теоретической вероятности выхода случайной величины за границы нормального разброса для заданного закона распределения.

7 Список литературы

- [1] Бабахина С. А., Баженов А. Н. Практикум по математической статистике: учеб. пособие. — СПб. : Санкт-Петербургский политехнический университет Петра Великого, 2026.
- [2] Максимов Ю. Д. Математика. Теория и практика по математической статистике. Конспект-справочник по теории вероятностей : учеб. пособие. — СПб. : Изд-во Политехн. ун-та, 2009. — 395 с.

8 Приложение

Исходный код программ доступен в репозитории на GitHub:
<https://github.com/Reichenau/math-stats-labs>