

Министерство науки и высшего образования Российской Федерации  
Федеральное государственное автономное образовательное учреждение  
высшего образования  
«Санкт-Петербургский политехнический университет Петра Великого»  
**Физико-механический институт**  
**Высшая школа прикладной математики и вычислительной  
физики**

**Отчёт по лабораторной работе № 4**

**Эмпирическая функция распределения и ядерные оценки  
плотности**

по дисциплине «Математическая статистика»

**Выполнил студент гр.**  
**5030102/30202:**  
Шильдт Д.С.

**Преподаватель:**  
Баженов А.Н.

Санкт-Петербург  
2026

## СОДЕРЖАНИЕ

|          |                                         |           |
|----------|-----------------------------------------|-----------|
| <b>1</b> | <b>Постановка задачи . . . . .</b>      | <b>3</b>  |
| <b>2</b> | <b>Теоретическая часть . . . . .</b>    | <b>3</b>  |
| <b>3</b> | <b>Реализация . . . . .</b>             | <b>4</b>  |
| 3.1      | Язык программирования и среда . . . . . | 4         |
| 3.2      | Используемые библиотеки . . . . .       | 4         |
| 3.3      | Суть реализованных методов . . . . .    | 5         |
| <b>4</b> | <b>Результаты . . . . .</b>             | <b>6</b>  |
| <b>5</b> | <b>Обсуждение . . . . .</b>             | <b>12</b> |
| <b>6</b> | <b>Выводы . . . . .</b>                 | <b>13</b> |
| <b>7</b> | <b>Список литературы . . . . .</b>      | <b>14</b> |
| <b>8</b> | <b>Приложение . . . . .</b>             | <b>14</b> |

# 1 Постановка задачи

## Цели и задачи работы:

- Освоить методы непараметрического оценивания неизвестной функции распределения и плотности вероятности по выборочным данным.
- Проанализировать влияние объема выборки на точность приближения теоретических кривых их эмпирическими оценками и сравнить ядерные оценки плотности с гистограммами.

**Задание:** Сгенерировать независимые выборки объемом  $n \in \{20, 60, 100\}$ . Построить на них:

1. Эмпирическую функцию распределения (э. ф. р.) и теоретическую функцию распределения.
2. Ядерную оценку плотности (ядро — гауссово) и теоретическую плотность

## 2 Теоретическая часть

Эмпирическая функция распределения  $F_n^*(x)$  выступает точечной статистической оценкой теоретической функции распределения  $F(x)$ . Она определяет относительную частоту события  $X < x$  для заданной выборки. Аналитически  $F_n^*(x)$  задается как неубывающая ступенчатая функция со скачками, равными  $1/n$ , в каждом элементе вариационного ряда:

$$F_n^*(x) = \frac{1}{n} \sum_{i=1}^n I(x_i < x), \quad (1)$$

где  $I(\cdot)$  — функция-индикатор, принимающая значение 1 при выполнении условия  $x_i < x$  и 0 в противном случае. По мере неограниченного роста объема выборки  $n$ , согласно фундаментальным предельным теоремам, эмпирическая функция равномерно сходится к истинной  $F(x)$ .

Ядерная оценка плотности  $\hat{f}_h(x)$  применяется для гладкого непараметрического восстановления неизвестной генеральной плотности вероят-

ности. Вычисление базируется на суперпозиции локальных ядер:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right), \quad (2)$$

где  $K(u)$  — весовая ядерная функция, удовлетворяющая нормировочному условию  $\int K(u)du = 1$ . Стандартной практикой является использование гауссовского ядра  $K(u) = \frac{1}{\sqrt{2\pi}}e^{-u^2/2}$ .

Степень гладкости итоговой кривой определяется параметром ширины полосы  $h$ . При недостаточном  $h$  график покрывается высокочастотными флуктуациями (недосглаживание), при избыточном — теряет структурные особенности распределения (пересглаживание). Оптимальный шаг интегрирования, минимизирующий среднеквадратичную ошибку, вычисляется по эмпирическому правилу Сильвермана:

$$h = 1.06 \cdot \hat{\sigma} \cdot n^{-1/5}, \quad (3)$$

где  $\hat{\sigma}$  — выборочное стандартное отклонение.

Специфика дискретных законов исключает применение непрерывного ядерного сглаживания. Для распределения Пуассона  $P(5)$  непрерывная оценка плотности лишена математического смысла, поэтому её аналогом на графиках выступает полигон относительных частот.

## 3 Реализация

### 3.1 Язык программирования и среда

- **Используемый язык:** Python 3.14.2
- **Используемая среда разработки:** Visual Studio Code

### 3.2 Используемые библиотеки

- **numpy** — использовалась для работы с массивами данных, сортировки выборок, вычисления сеток значений и агрегирования метрик.

- **scipy** — использовалась для генерации выборок из теоретических распределений и вычисления функций распределения/плотности.
- **matplotlib** — использовалась для построения графиков эмпирической функции распределения, ядерной оценки плотности и сохранения итоговых рисунков.
- **pathlib** — использовалась для автоматического создания каталогов и записи итоговых PNG-файлов и CSV-таблицы.

### 3.3 Суть реализованных методов

- `getDistributionConfigs()` — формирует список исследуемых распределений и задает для каждого из них генератор выборки, теоретическую функцию распределения и теоретическую плотность.
- `makeEcdf(sample)` — строит эмпирическую функцию распределения по отсортированной выборке и возвращает вариационный ряд вместе с накопленными относительными частотами.
- `plotEcdf(ax, sample, config, sample_size)` — выводит на одном графике эмпирическую и теоретическую функции распределения для выбранного объема выборки.
- `plotDensity(ax, sample, config, sample_size)` — строит ядерную оценку плотности для непрерывных распределений; для Пуассона используется полигон относительных частот и теоретическая вероятность.
- `computeErrorMetrics(sample, config)` — вычисляет максимальное отклонение эмпирической функции распределения от теоретической и среднеквадратичную ошибку оценки плотности.
- `saveDistributionFigure(config, rng)` — формирует итоговый рисунок для одного распределения и сохраняет его в каталог `figures`.
- `saveCsv(rows)` и `printReport(rows)` — отвечают за экспорт численных результатов в файл `ecdf_kde_metrics.csv` и вывод сводки в консоль.


## 4 Результаты

В ходе статистического моделирования для каждого распределения построены отдельные блоки графиков: сначала показаны эмпирическая и теоретическая функции распределения, ниже — оценка плотности и теоретическая плотность (рис. 1–5).


Количественные метрики отклонений эмпирических кривых от теоретических представлены в таблице 1. Значения округлены до четырех знаков после запятой.

Таблица 1: Метрики отклонения эмпирических оценок от теоретических функций

| Распределение                        | n   | $\max  \mathbf{F}_n^*(\mathbf{x}) - \mathbf{F}(\mathbf{x}) $ | MSE плотности |
|--------------------------------------|-----|--------------------------------------------------------------|---------------|
| Нормальное $N(0, 1)$                 | 20  | 0.1300                                                       | 0.0011        |
|                                      | 60  | 0.1089                                                       | 0.0015        |
|                                      | 100 | 0.1216                                                       | 0.0010        |
| Коши $C(0, 1)$                       | 20  | 0.1338                                                       | 0.0041        |
|                                      | 60  | 0.0867                                                       | 0.0048        |
|                                      | 100 | 0.0580                                                       | 0.0028        |
| Лапласа $L(0, 1/\sqrt{2})$           | 20  | 0.1142                                                       | 0.0016        |
|                                      | 60  | 0.1287                                                       | 0.0065        |
|                                      | 100 | 0.0676                                                       | 0.0008        |
| Пуассона $P(5)$                      | 20  | 0.0819                                                       | 0.0004        |
|                                      | 60  | 0.0348                                                       | 0.0001        |
|                                      | 100 | 0.0478                                                       | 0.0007        |
| Равномерное $U(-\sqrt{3}, \sqrt{3})$ | 20  | 0.1698                                                       | 0.0032        |
|                                      | 60  | 0.1337                                                       | 0.0023        |
|                                      | 100 | 0.0513                                                       | 0.0020        |




(а) Эмпирическая и теоретическая функции распределения




(б) Ядерная и теоретическая плотности

Рис. 1: Графики для нормального распределения  $N(0, 1)$




(а) Эмпирическая и теоретическая функции распределения




(б) Ядерная и теоретическая плотности

Рис. 2: Графики для распределения Коши  $C(0, 1)$




(а) Эмпирическая и теоретическая функции распределения




(б) Ядерная и теоретическая плотности

Рис. 3: Графики для распределения Лапласа  $L(0, 1/\sqrt{2})$




(а) Эмпирическая и теоретическая функции распределения




(б) Полигон относительных частот и теоретическая вероятность

Рис. 4: Графики для распределения Пуассона  $P(5)$



(а) Эмпирическая и теоретическая функции распределения



(б) Ядерная и теоретическая плотности

Рис. 5: Графики для равномерного распределения  $U(-\sqrt{3}, \sqrt{3})$

## 5 Обсуждение

Анализ вычисленных метрик отклонения подтверждает теоретические положения о сходимости непараметрических оценок к генеральным функциям.

Максимальная абсолютная ошибка эмпирической функции распределения  $D_n$  в большинстве случаев закономерно убывает с ростом  $n$ , что эмпирически доказывает теорему Гливленко-Кантелли о равномерной сходимости. Наиболее четко эта динамика отслеживается на распределениях без острых пиков и тяжелых хвостов в центральной части: для равномерного закона ошибка строго снижается с 0.1698 при  $n = 20$  до 0.0513 при  $n = 100$ , для распределения Коши падает с 0.1338 до 0.0580. Зафиксированные локальные статистические колебания  $D_n$  при переходе от  $n = 60$  к  $n = 100$  для нормального закона (рост с 0.1089 до 0.1216) и закона Пуассона ( $0.0348 \rightarrow 0.0478$ ) обусловлены исключительно случайным характером генерации конкретных реализаций, однако абсолютные значения остаются в допустимых пределах статистической погрешности.

Точность ядерной оценки плотности ( $MSE$ ) заметно зависит от формы хвостов распределения, поскольку именно она влияет на выбор ширины полосы  $h$  по правилу Сильвермана. Для стандартного нормального закона алгоритм подбирает адекватный шаг сглаживания: среднеквадратичная ошибка минимальна и стабилизируется на уровне 0.0010 при  $n = 100$ . Для равномерного закона также получено достаточно точное приближение ( $MSE = 0.0020$ ).

На распределении Коши качество аппроксимации заметно ниже. Тяжелые хвосты увеличивают выборочное стандартное отклонение  $\hat{\sigma}$ , из-за чего правило Сильвермана задает более широкую полосу  $h$  и возникает пересглаживание графика плотности. В результате  $MSE$  для закона Коши в 2–3 раза выше, чем для нормального закона (0.0048 при  $n = 60$ , 0.0028 при  $n = 100$ ). Для распределения Лапласа гауссовское ядро частично сглаживает острый пик плотности в нуле, однако при  $n = 100$  итоговая ошибка остается небольшой (0.0008).

В случае дискретного закона Пуассона полигон относительных частот хорошо согласуется с теоретической функцией вероятностей: расчетная ошибка  $MSE$  мала и составляет 0.0001 при  $n = 60$  и 0.0007 при

$n = 100$ . Сравнение ядерных оценок с гистограммами выявляет системные аналитические различия методов. Гистограмма представляет собой кусочно-постоянную аппроксимацию, чувствительную к шагу разбиения. KDE формирует строго непрерывную гладкую кривую.

Для нормального закона и распределения Лапласа при  $n = 100$  ядерное сглаживание дает визуально более точное совпадение с теоретической плотностью, полностью устраняя ступенчатые артефакты гистограмм. Однако на границах финитных законов метод дает сбой. Для равномерного распределения  $U(-\sqrt{3}, \sqrt{3})$  суперпозиция гауссовских ядер генерирует фиктивные вероятностные «хвосты» за пределами интервала  $[-\sqrt{3}, \sqrt{3}]$ . Гистограмма в данном случае точнее отражает отсутствие вероятностной массы за границами отрезка.

При анализе распределения Коши  $C(0, 1)$  гистограмма уверенно локализует центральный пик даже при наличии выбросов. Ядерная оценка с этим не справляется: аномальный рост выборочного стандартного отклонения  $\hat{\sigma}$  из-за тяжелых хвостов приводит к завышению параметра  $h$  и критическому пересглаживанию кривой KDE.

## 6 Выводы

Методами статистического моделирования исследована сходимость эмпирических функций распределения (ЭФР) и ядерных оценок плотности (KDE).

Экспериментально подтверждено, что ЭФР является универсальным инструментом непараметрического анализа одномерных данных. С увеличением объема выборки до  $n = 100$  статистика Колмогорова  $D_n$  снижается, обеспечивая надежное приближение к истинной функции распределения независимо от ее аналитического вида.

Установлено, что точность ядерного сглаживания с применением гауссовского ядра и правила Сильвермана зависит от структуры хвостов распределения. Для законов с экспоненциальными и финитными хвостами (Нормальное, Равномерное, Лапласа) метод обеспечивает хорошее качество аппроксимации и малую среднеквадратичную ошибку ( $MSE \leq 0.0020$ ). Для распределения Коши наблюдается пересглаживание

из-за увеличенной полосы пропускания  $h$ , что ухудшает восстановление истинной плотности вероятности. Сравнительный анализ методов восстановления плотности показал, что ядерное сглаживание (KDE) превосходит классические гистограммы при аппроксимации непрерывных распределений с экспоненциально убывающими хвостами. При анализе финитных законов (Равномерное) и распределений без конечных моментов (Коши) KDE уступает гистограммам из-за краевых эффектов и неробастности алгоритма вычисления ширины полосы  $h$ , что приводит к искажению истинной формы генеральной плотности.

## 7 Список литературы

- [1] Бабахина С. А., Баженов А. Н. Практикум по математической статистике: учеб. пособие. — СПб. : Санкт-Петербургский политехнический университет Петра Великого, 2026.
- [2] Максимов Ю. Д. Математика. Теория и практика по математической статистике. Конспект-справочник по теории вероятностей : учеб. пособие. — СПб. : Изд-во Политехн. ун-та, 2009. — 395 с.

## 8 Приложение

Исходный код программ доступен в репозитории на GitHub:  
<https://github.com/Reichenau/math-stats-labs>