

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Санкт-Петербургский политехнический университет Петра Великого»
Физико-механический институт
**Высшая школа прикладной математики и вычислительной
физики**

Отчёт по лабораторной работе № 5

Корреляционный анализ и эллипсы рассеивания
по дисциплине «Математическая статистика»

Выполнил студент гр.
5030102/30202:
Шильдт Д.С.

Преподаватель:
Баженов А.Н.

Санкт-Петербург
2026

СОДЕРЖАНИЕ

1	Постановка задачи	3
2	Теоретическая часть	3
3	Реализация	5
3.1	Язык программирования и среда	5
3.2	Используемые библиотеки	5
3.3	Суть реализованных методов	6
4	Результаты	7
5	Обсуждение	10
6	Выводы	10
7	Список литературы	11
8	Приложение	11

1 Постановка задачи

Задание:

1. Сгенерировать двумерные выборки (x, y) объёмом $n = 20, 60, 100$ из:
 - Двумерного нормального распределения $N(0, 0, 1, 1, \rho)$ с $\rho = 0, 0.5, 0.9$.
 - Смеси: $0.9N(0, 0, 1, 1, 0.9) + 0.1N(0, 0, 10, 10, -0.9)$.
2. Для каждой выборки вычислить коэффициенты корреляции Пирсона, Спирмена и квадрантный. Повторить 1000 раз, найти средние и дисперсии.
3. Построить диаграммы рассеяния и эллипсы равновероятности.

Цели и задачи:

- Сравнить исходное значение коэффициента корреляции с вычисленными.
- Изучить способы визуализации ковариационной структуры данных.

2 Теоретическая часть

Двумерная случайная величина (X, Y) называется распределённой нормально, если её плотность вероятности определена формулой:

$$N(x, y, \bar{x}, \bar{y}, \sigma_x, \sigma_y, \rho) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}} \times \\ \times \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x-\bar{x})^2}{\sigma_x^2} - 2\rho \frac{(x-\bar{x})(y-\bar{y})}{\sigma_x\sigma_y} + \frac{(y-\bar{y})^2}{\sigma_y^2} \right] \right\}$$

где $\bar{x}, \bar{y}$ — математические ожидания, σ_x, σ_y — средние квадратические отклонения компонент, ρ — коэффициент корреляции.

Для количественной оценки степени линейной зависимости между компонентами выборки $\{(x_i, y_i)\}_{i=1}^n$ применяется выборочный коэффициент

ент корреляции Пирсона r :

$$r = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{K}{s_X s_Y},$$

где K, s_X^2, s_Y^2 — выборочные ковариации и дисперсии с.в. X и Y .

Выборочный коэффициент ранговой корреляции Спирмена определяется как выборочный коэффициент корреляции Пирсона между рангами u, v переменных X, Y :

$$r_S = \frac{\frac{1}{n} \sum (u_i - \bar{u})(v_i - \bar{v})}{\sqrt{\frac{1}{n} \sum (u_i - \bar{u})^2 \frac{1}{n} \sum (v_i - \bar{v})^2}},$$

где $\bar{u} = \bar{v} = \frac{1+2+\dots+n}{n} = \frac{n+1}{2}$ — среднее значение рангов.

Выборочный квадрантный коэффициент корреляции:

$$r_Q = \frac{(n_1 + n_3) - (n_2 + n_4)}{n}.$$

где n_1, n_2, n_3 и n_4 — количества точек с координатами (x_i, y_i) , попавших соответственно в 1, 2, 3 и 4 квадранты декартовой системы с осями $x' = x - \text{med}(x)$, $y' = y - \text{med}(y)$ и с центром в точке $(\text{med}(x), \text{med}(y))$.

Для смеси распределений в данной работе используется линейная комбинация двух независимых выборок:

$$X = 0.9X_1 + 0.1X_2, \quad Y = 0.9Y_1 + 0.1Y_2,$$

где $(X_1, Y_1) \sim N(0, 0, 1, 1, 0.9)$, $(X_2, Y_2) \sim N(0, 0, 10, 10, -0.9)$. Так как компоненты независимы и имеют нулевые математические ожидания, для смеси получаем

$$D_X = D_Y = 0.9^2 \cdot 1 + 0.1^2 \cdot 10 = 0.91,$$

$$\text{cov}(X, Y) = 0.9^2 \cdot 0.9 + 0.1^2 \cdot (-9) = 0.639.$$

Следовательно, коэффициент корреляции смеси равен

$$r_{XY} = \frac{\text{cov}(X, Y)}{\sqrt{D_X D_Y}} = \frac{0.639}{\sqrt{0.91 \cdot 0.91}} \approx 0.7022.$$

Геометрическим местом точек плоскости, в которых плотность двумерного нормального распределения сохраняет постоянное значение, выступают эллипсы равновероятности (эллипсы рассеивания). Аналитическое уравнение проекции эллипса:

$$\frac{(x - \bar{x})^2}{\sigma_x^2} - 2\rho \frac{(x - \bar{x})(y - \bar{y})}{\sigma_x \sigma_y} + \frac{(y - \bar{y})^2}{\sigma_y^2} = \text{const}.$$

Ориентация эллипса относительно координатных осей жестко зависит от коэффициента корреляции ρ . Угол наклона главных осей симметрии α вычисляется из соотношения:

$$\tan 2\alpha = \frac{2\rho\sigma_x\sigma_y}{\sigma_x^2 - \sigma_y^2}.$$

3 Реализация

3.1 Язык программирования и среда

- **Используемый язык:** Python 3.14.2
- **Используемая среда разработки:** Visual Studio Code

3.2 Используемые библиотеки

- **numpy** — применяется для векторных вычислений, операций с ковариационными матрицами, нахождения собственных значений и векторов, вычисления медиан, а также расчета выборочного коэффициента корреляции Пирсона.
- **scipy.stats** — используется для генерации многомерных случайных величин (`multivariate_normal`), вычисления ранговой корреляции Спирмена и определения квантилей распределения χ^2 .
- **math** — предоставляет тригонометрические функции (`atan2`, `degrees`) для аналитического вычисления угла наклона главных осей эллипса рассеивания.

- **matplotlib.pyplot** — обеспечивает построение диаграмм рассеяния и визуализацию эллипсов равновероятности на координатной плоскости.
- **pathlib** — используется для определения пути и сохранения итоговых файлов таблиц и графиков.

3.3 Суть реализованных методов

- `generate_bivariate_normal(n, rho, rng)` и `generate_mixture(n, rng)` — функции формирования двумерных выборок. Первая генерирует данные из нормального распределения с использованием заданной ковариационной матрицы, зависящей от параметра ρ . Вторая формирует смесь как линейную комбинацию двух независимых выборок с весами 0.9 и 0.1.
- `pearson_corr(x, y)`, `spearman_corr(x, y)` и `quadrant_corr(x, y)` — реализуют расчет исследуемых коэффициентов корреляции. Квадрантный коэффициент вычисляется алгоритмически.
- `ellipse_parameters(x, y, prob)` — вычисляет полуоси a , b и угол наклона α для эллипса рассеивания.
- `run_experiments()` — запускает цикл из 1000 итераций генерации выборок заданного объема для вычисления математического ожидания $E(z)$ и дисперсии $D(z)$ точечных оценок коэффициентов корреляции.
- `plot_normals_grouped_by_sample(...)` и `plot_mixture_grouped_by_sample(...)` — выполняют компоновку диаграмм рассеяния с наложением вычисленных эллипсов в формате группировки по объему выборки.
- `save_csv_stats(rows)` и `save_csv_ellipses(rows)` — обеспечивают объединение и экспорт рассчитанных числовых характеристик и геометрических параметров эллипсов в CSV-файлы.

4 Результаты

В разделе представлены практические результаты. Оценки коэффициентов корреляции Пирсона (r), Спирмена (r_S) и квадрантного коэффициента (r_Q) получены путем усреднения по 1000 независимым экспериментам для каждого объема выборки $n = 20, 60$ и 100 .

Таблица 1: Оценки коэффициентов корреляции для двумерного нормального распределения

ρ	Коэффициент	n = 20	n = 60	n = 100
0.0	Пирсона r	0.0026 ± 0.2307	-0.0019 ± 0.1315	0.0009 ± 0.1012
	Спирмена r_S	0.0044 ± 0.2322	-0.0024 ± 0.1324	0.0011 ± 0.1018
	Квадрантный r_Q	-0.0006 ± 0.2281	-0.0049 ± 0.1334	0.0044 ± 0.1050
0.5	Пирсона r	0.4791 ± 0.1852	0.4973 ± 0.0991	0.4966 ± 0.0759
	Спирмена r_S	0.4465 ± 0.1943	0.4751 ± 0.1058	0.4777 ± 0.0811
	Квадрантный r_Q	0.3038 ± 0.2203	0.3303 ± 0.1238	0.3301 ± 0.0970
0.9	Пирсона r	0.8933 ± 0.0519	0.8975 ± 0.0267	0.8990 ± 0.0195
	Спирмена r_S	0.8639 ± 0.0708	0.8818 ± 0.0344	0.8856 ± 0.0254
	Квадрантный r_Q	0.7014 ± 0.1668	0.6999 ± 0.0898	0.7096 ± 0.0710

Таблица 2: Оценки коэффициентов корреляции для смеси нормальных распределений

Коэффициент	n = 20	n = 60	n = 100
Пирсона r	0.6920 ± 0.0160	0.6978 ± 0.0044	0.7002 ± 0.0027
Спирмена r_S	0.6575 ± 0.0197	0.6752 ± 0.0054	0.6796 ± 0.0036
Квадрантный r_Q	0.4850 ± 0.0395	0.4896 ± 0.0127	0.4932 ± 0.0077

Таблица 3: Теоретическая корреляция смеси как линейной комбинации

D_X	D_Y	$\text{cov}(X, Y)$	r_{XY}
0.9100	0.9100	0.6390	0.7022

Геометрические параметры эллипсов рассеивания, усредненные по 1000 независимым экспериментам (большая полуось a , малая полуось b и угол наклона главных осей α), представлены в таблице 4 для всех рассматриваемых объемов выборки.

Таблица 4: Усредненные параметры эллипсов рассеивания

Распределение	Параметр	n = 20	n = 60	n = 100
Нормальное, $\rho = 0.0$	a	2.7706	2.6449	2.5883
	b	2.0490	2.2370	2.2789
	$\alpha, ^\circ$	0.6766	1.7883	0.5459
	$\bar{x}$	-0.0028	-0.0008	0.0004
	$\bar{y}$	0.0117	-0.0097	0.0038
Нормальное, $\rho = 0.5$	a	2.9950	3.0006	2.9952
	b	1.6489	1.7005	1.7149
	$\alpha, ^\circ$	43.7322	44.6956	45.0130
	$\bar{x}$	0.0011	0.0045	0.0035
	$\bar{y}$	0.0099	0.0034	0.0030
Нормальное, $\rho = 0.9$	a	3.3371	3.3595	3.3597
	b	0.7470	0.7665	0.7670
	$\alpha, ^\circ$	44.9354	45.0260	45.0350
	$\bar{x}$	-0.0042	0.0021	-0.0043
	$\bar{y}$	-0.0010	0.0025	-0.0020
Смесь распределений	a	3.0280	3.0295	3.0448
	b	1.2145	1.2558	1.2646
	$\alpha, ^\circ$	45.0555	45.0781	44.9271
	$\bar{x}$	-0.0051	-0.0019	0.0011
	$\bar{y}$	-0.0035	0.0027	-0.0018

Построены диаграммы рассеяния. Графики нормального закона (рис. 1–3), графики для смеси (рис. 4).




Рис. 1: Диаграммы рассеяния для нормального распределения, $n = 20$




Рис. 2: Диаграммы рассеяния для нормального распределения, $n = 60$




Рис. 3: Диаграммы рассеяния для нормального распределения, $n = 100$




Рис. 4: Диаграммы рассеяния для смеси распределений

5 Обсуждение

Для двумерного нормального закона выборочный коэффициент Пирсона r выступает наиболее эффективной статистической оценкой линейной зависимости. Эмпирические данные подтверждают минимальный разброс этой величины по сравнению с ранговыми аналогами: при $\rho = 0.9$ и $n = 100$ стандартное отклонение $\sqrt{D(r)}$ составляет 0.0195, тогда как для коэффициента Спирмена $\sqrt{D(r_S)} = 0.0254$, а для квадрантного $\sqrt{D(r_Q)} = 0.0710$. Увеличение объема выборки от $n = 20$ до $n = 100$ приводит к закономерному убыванию дисперсий всех рассматриваемых оценок (табл. 1).

Для смеси получено теоретическое значение $r_{XY} \approx 0.7022$ при $D_X = D_Y = 0.91$ и $\text{cov}(X, Y) = 0.639$ (табл. 3).

Исследование смеси распределений показывает, что коэффициент Пирсона остается устойчиво положительным и быстро приближается к теоретическому значению из табл. 3. При $n = 100$ получено $E(r) = 0.7002$, а отклонение от теоретического значения 0.7022 является минимальным среди рассмотренных объемов выборки. Коэффициенты Спирмена и квадрантный также остаются положительными, но дают более консервативные оценки зависимости: $E(r_S) = 0.6796$ и $E(r_Q) = 0.4932$ (табл. 2).

Для независимых нормальных величин ($\rho = 0.0$) полуоси близки ($a = 2.5883$, $b = 2.2789$ при $n = 100$), а угол наклона главной оси остается близким к нулю, что соответствует отсутствию выраженной направленности эллипса. При росте корреляции до $\rho = 0.9$ эллипс заметно вытягивается, а угол стабилизируется около 45° ($a = 3.3597$, $b = 0.7670$, $\alpha = 45.0350$). Для смеси при $n = 100$ получено $a = 3.0448$, $b = 1.2646$, $\alpha = 44.9271$ (табл. 4).

6 Выводы

Для двумерного нормального распределения наиболее эффективной мерой линейной зависимости выступает коэффициент Пирсона r . При $\rho = 0.9$ и $n = 100$ он обеспечивает минимальную дисперсию оценки ($\sqrt{D(r)} = 0.0195$) по сравнению с ранговым r_S и квадрантным r_Q коэффициентами. Увеличение объема выборки закономерно снижает статистический разброс

всех вычисляемых характеристик.

Для смеси, реализованной как линейная комбинация двух выборок, выборочный коэффициент Пирсона дает значение, близкое к теоретическому: при $n = 100$ получено $E(r) = 0.7002$ против теоретического 0.7022. Ранговый и квадрантный коэффициенты также сохраняют положительный знак, но по величине отстают от Пирсона: $E(r_S) = 0.6796$, $E(r_Q) = 0.4932$.

Геометрические параметры эллипсов рассеивания жестко зависят от ковариационной структуры. Для независимых случайных величин ($\rho = 0.0$) эллипс близок к окружности. Рост коэффициента корреляции до $\rho = 0.9$ приводит к выраженному вытягиванию фигуры вдоль главной оси ($a/b \approx 4.38$ для $n = 100$), при этом угол наклона стабилизируется около 45° . Для смеси при $n = 100$ получены параметры $a = 3.0448$, $b = 1.2646$, $\alpha = 44.9271$, что соответствует выраженному вытягиванию эллипса и наклону главной оси около 45° .

7 Список литературы

- [1] Бабахина С. А., Баженов А. Н. Практикум по математической статистике: учеб. пособие. — СПб. : Санкт-Петербургский политехнический университет Петра Великого, 2026.
- [2] Максимов Ю. Д. Математика. Теория и практика по математической статистике. Конспект-справочник по теории вероятностей : учеб. пособие. — СПб. : Изд-во Политехн. ун-та, 2009. — 395 с.

8 Приложение

Исходный код программ доступен в репозитории на GitHub:
<https://github.com/Reichenau/math-stats-labs>