

Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Санкт-Петербургский политехнический университет Петра Великого»
Физико-механический институт
**Высшая школа прикладной математики и вычислительной
физики**

Отчёт по лабораторной работе № 7

Проверка гипотез о законе распределения. Критерий χ^2
по дисциплине «Математическая статистика»

Выполнил студент гр.
5030102/30202:
Шильдт Д.С.

Преподаватель:
Баженов А.Н.

Санкт-Петербург
2026

СОДЕРЖАНИЕ

1	Постановка задачи	3
2	Теоретическая часть	3
2.1	Используемые распределения	3
2.2	Метод максимального правдоподобия	4
2.3	Критерий хи-квадрат Пирсона	5
3	Реализация	5
3.1	Язык программирования и среда	5
3.2	Используемые библиотеки	6
3.3	Суть реализованных методов	6
4	Результаты	7
5	Обсуждение	9
6	Выводы	10
7	Список литературы	11
8	Приложение	11

1 Постановка задачи

Задание:

1. Сгенерировать выборку объемом $n = 100$ из $N(0, 1)$.
2. Оценить параметры μ, σ методом максимального правдоподобия (ММП).
3. Проверить гипотезу H_0 : выборка из $N(\hat{\mu}, \hat{\sigma})$ с помощью критерия χ^2 при $\alpha = 0.05$.
4. Исследовать чувствительность критерия: сгенерировать выборки из равномерного распределения и распределения Лапласа ($n = 20$) и проверить их на нормальность.

Цели и задачи:

- Исследовать принцип работы критерия χ^2 и его ограничения.
- Оценить мощность критерия при альтернативных распределениях.

2 Теоретическая часть

2.1 Используемые распределения

Анализ чувствительности *критерия согласия* осуществляется на базе трех непрерывных распределений с заданными плотностями вероятности:

1. **Нормальный закон** $N(0, 1)$:

$$f(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right)$$

2. **Распределение Лапласа** $L(0, 1/\sqrt{2})$:

$$f(x) = \frac{1}{\sqrt{2}} \exp\left(-\sqrt{2}|x|\right)$$

3. Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$:

$$f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, & x \in [-\sqrt{3}, \sqrt{3}] \\ 0, & x \notin [-\sqrt{3}, \sqrt{3}] \end{cases}$$

2.2 Метод максимального правдоподобия

Для оценки неизвестных параметров сдвига m и масштаба σ нормальной генеральной совокупности применяется метод максимального правдоподобия [1]. Функция правдоподобия L для выборки $(x_1, \dots, x_n)$:

$$\begin{aligned} L(x_1, \dots, x_n, \mu, \sigma) &= \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{(x_i - \mu)^2}{2\sigma^2} \right\} = \\ &= (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\}, \end{aligned}$$

Оценки параметров определяются точкой глобального максимума данной функции. Переход к логарифмической функции правдоподобия упрощает дифференцирование:

$$\ln L = -\frac{n}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

Необходимое условие экстремума требует равенства нулю частных производных по оцениваемым параметрам μ и σ^2 . Получим следующие уравнения правдоподобия:

$$\begin{cases} \frac{\partial \ln L}{\partial \mu} = \frac{1}{\hat{\sigma}^2} \sum_{i=1}^n (x_i - \hat{\mu}) = \frac{n}{\hat{\sigma}^2} (\bar{x} - \hat{\mu}) = 0, \\ \frac{\partial \ln L}{\partial (\sigma^2)} = -\frac{n}{2\hat{\sigma}^2} + \frac{1}{2(\hat{\sigma}^2)^2} \sum_{i=1}^n (x_i - \hat{\mu})^2 = \\ = \frac{n}{2(\hat{\sigma}^2)^2} \left[\frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2 - \hat{\sigma}^2 \right] = 0, \end{cases}$$

Решение полученной системы нормальных уравнений устанавливает выборочное среднее в качестве точечной оценки математического ожида-

ния и выборочную дисперсию в качестве оценки генеральной дисперсии [2]:

$$\hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu})^2}.$$

2.3 Критерий хи-квадрат Пирсона

Проверка нулевой гипотезы H_0 реализуется с помощью непараметрического критерия χ^2 Пирсона. Выборочное пространство разбивается на k непересекающихся интервалов. *Статистика критерия хи-квадрат* К.Пирсона [1] имеет вид:

$$\chi^2 = \sum_{i=1}^k \frac{n}{p_i} \left(\frac{n_i}{n} - p_i \right)^2 = \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i}.$$

где

$k \approx 1.72\sqrt[3]{n}$ — формула Террелла;

$k \approx 1 + 3.3 \lg n$ — формула Стерджеса.

Теоретическая вероятность p_i вычисляется интегрированием плотности нормального распределения с найденными параметрами $\hat{\mu}$ и $\hat{\sigma}$ на i -м интервале группировки.

Сходимость распределения статистики к закону хи-квадрат обеспечивается жестким ограничением $np_i \geq 5$. Число степеней свободы предельного распределения корректируется по теореме Фишера как $s = k - 1 - l$, где $l = 2$ — количество параметров, оцененных по исследуемой выборке. Критическая область формируется правосторонней: если вычисленная статистика χ^2 превышает квантиль $\chi_{1-\alpha}^2(s)$ при заданном уровне значимости α , нулевая гипотеза H_0 отвергается.

3 Реализация

3.1 Язык программирования и среда

- **Используемый язык:** Python 3.14.2
- **Используемая среда разработки:** Visual Studio Code

3.2 Используемые библиотеки

- **numpy** — применяется для генерации выборок, вычисления точечных оценок параметров методом максимального правдоподобия, а также для объединения эмпирических частот.
- **scipy.stats** — используется для определения теоретических вероятностей попадания случайной величины в интервалы группировки и вычисления критических квантилей предельного распределения χ^2 .
- **matplotlib.pyplot** — используется для построения гистограмм и визуализации итоговых зависимостей.
- **pathlib** — используется для автоматического определения пути и сохранения итоговых файлов таблиц и графиков.

3.3 Суть реализованных методов

- `generate_normal_sample(n, rng)`, `generate_uniform_sample(n, rng)` и `generate_laplace_sample(n, rng)` — функции формирования независимых выборок заданного объема n из нормального закона $N(0, 1)$, равномерного $U(-\sqrt{3}, \sqrt{3})$ и распределения Лапласа $L(0, 1/\sqrt{2})$ соответственно.
- `estimate_normal_parameters(sample)` — алгоритм расчета оценок параметров сдвига $\hat{\mu}$ и масштаба $\hat{\sigma}$ гипотетического нормального распределения методом максимального правдоподобия на основе исследуемой выборки.
- `choose_bin_count(n)` — определяет количество интервалов группировки k по формуле Стерджеса.
- `merge_small_frequency_bins(observed, expected, edges, min_freq=5)` — процедура объединения соседних интервалов при нарушении условия $np_i \geq 5$. Алгоритм приоритизирует объединение граничных интервалов, затем обрабатывает внутренние интервалы с малыми ожидаемыми частотами.

- `chi_square_normal_test(sample, alpha)` — вычисления критерия Пирсона с применением процедуры объединения интервалов. Формирует границы интервалов, рассчитывает эмпирические частоты n_i и теоретически ожидаемые np_i , выполняет объединение при необходимости. Возвращает значение вычисленной статистики χ^2 , скорректированное число степеней свободы и логический результат проверки гипотезы H_0 .
- `evaluate_sensitivity(...)` — реализует цикл из 1000 итераций генерации выборок малого объема ($n = 20$) из альтернативных законов и формирует эмпирическую оценку чувствительности критерия.
- `build_breakdown_rows(...)` — формирует построчные данные разбиений для итоговых таблиц.
- `save_single_result_csv(...)`, `save_breakdown_csv(...)`, `save_sensitivity_csv(...)` и `save_sample_csv(...)` — функции сохранения рассчитанных таблиц в формате CSV.
- `save_figures(...)` и `save_sensitivity_figure(...)` — функции построения и сохранения графиков.

4 Результаты

В таблице 1 приведены итоговые значения оценок параметров $\hat{\mu}$ и $\hat{\sigma}$, вычисленные значения статистики χ_B^2 , соответствующие критические уровни и решение по нулевой гипотезе для каждой исследуемой выборки.

Таблица 1: Сводные результаты проверки гипотез о нормальности распределения

Распределение	n	$\hat{\mu}$	$\hat{\sigma}$	χ_B^2	$\chi_{1-\alpha}^2(c)$	Результат
Нормальное	100	-0.0503	0.7728	2.9944	7.8147	Принимается
Равномерное	20	0.1384	0.8759	0.6573	3.8415	Принимается
Лапласа	20	-0.2938	0.9327	3.4335	3.8415	Принимается

Таблица 2: Разбиение и расчет χ^2 для нормального распределения ($n = 100$, $k = 6$, $c = 3$)

i	Интервал Δ_i	n_i	p_i	np_i	$n_i - np_i$	$\frac{(n_i - np_i)^2}{np_i}$
1	$(-\infty, -0.9279]$	13	0.1281	12.8056	0.1944	0.0030
2	$(-0.9279, -0.4163]$	19	0.1898	18.9828	0.0172	0.0000
3	$(-0.4163, 0.0953]$	21	0.2568	25.6826	-4.6826	0.8538
4	$(0.0953, 0.6069]$	24	0.2277	22.7733	1.2267	0.0661
5	$(0.6069, 1.1185]$	18	0.1323	13.2338	4.7662	1.7165
6	$(1.1185, +\infty)$	5	0.0652	6.5218	-1.5218	0.3551
СУММА		100	1.0000	100.0000	0.0000	2.9944

Таблица 3: Разбиение и расчет χ^2 для равномерного распределения ($n = 20$, $k = 3$, $c = 0$)

i	Интервал Δ_i	n_i	p_i	np_i	$n_i - np_i$	$\frac{(n_i - np_i)^2}{np_i}$
1	$(-\infty, -0.1888]$	7	0.3544	7.0871	-0.0871	0.0011
2	$(-0.1888, 0.4159]$	4	0.2700	5.3988	-1.3988	0.3624
3	$(0.4159, +\infty)$	9	0.3757	7.5141	1.4859	0.2938
СУММА		20	1.0000	20.0000	0.0000	0.6573

Таблица 4: Разбиение и расчет χ^2 для распределения Лапласа ($n = 20$, $k = 3$, $c = 0$)

i	Интервал Δ_i	n_i	p_i	np_i	$n_i - np_i$	$\frac{(n_i - np_i)^2}{np_i}$
1	$(-\infty, -0.6056]$	7	0.1691	7.3816	-0.3816	0.0197
2	$(-0.6056, 0.1832]$	10	0.3264	6.5284	3.4716	1.8460
3	$(0.1832, +\infty)$	3	0.5045	6.0899	-3.0899	1.5678
СУММА		20	1.0000	20.0000	0.0000	3.4335

В таблице 5 приведены показатели чувствительности критерия по 1000 повторениям: доля отвержений гипотезы и среднее значение статистики χ_B^2 для каждого альтернативного распределения.

Таблица 5: Эмпирическая чувствительность критерия χ^2 к отклонениям от нормальности (1000 итераций, $n = 20$)

Истинное распределение	n	Доля отвергнутых гипотез	Среднее значение χ_B^2
Равномерное $U(-\sqrt{3}, \sqrt{3})$	20	0.041	0.950
Лапласа $L(0, 1/\sqrt{2})$	20	0.086	1.282

Графики гистограммы плотностей приведенных частот с наложением аналитических кривых плотности гипотетического нормального распределения $N(\hat{\mu}, \hat{\sigma})$.




Рис. 1: Гистограммы выборок и плотности нормального распределения $N(\hat{\mu}, \hat{\sigma})$

5 Обсуждение

При проверке истинной нулевой гипотезы на нормальной выборке ($n = 100$) вычисленная статистика $\chi_B^2 = 2.9944$ меньше критической квантили 7.8147. Гипотеза правомерно принимается. Формирование первоначально $k_0 = 8$ интервалов было произведено по формуле Стерджеса. Применение условия $np_i \geq 5$ для минимальных ожидаемых частот вынудило объединить крайние интервалы, в результате чего было получено $k = 6$ интервалов с сохранением $s = 3$ степеней свободы для предельного распределения.

Анализ альтернативных законов на малых выборках ($n = 20$) выявил критическую роль этапа объединения интервалов. При использовании первоначального разбиения ($k_0 = 5$) множество интервалов имели $np_i < 5$, нарушая требования теоремы. После объединения граничных интервалов остались только $k = 3$ основных интервала, все с ожидаемыми частотами ≥ 5.3 . С учетом оценки двух параметров число степеней свободы стало $s = 0$, что в реализации формально трактуется как $s = 1$ (минимально допустимое значение для распределения хи-квадрат).

Для равномерного закона вычисленная статистика $\chi_B^2 = 0.6573$ значительно ниже критического порога 3.8415, что приводит к принятию гипотезы о нормальности несмотря на явное отличие распределения. Объ-

единение широких интервалов привело к сглаживанию структуры эмпирического распределения, маскируя истинное отклонение от нормальности.

Распределение Лапласа с тяжелыми хвостами демонстрирует близкую ситуацию. Вычисленная статистика $\chi_B^2 = 3.4335$ лишь немного меньше критической границы 3.8415, хотя и не достигает уровня отклонения. Несмотря на наличие значительной асимметрии в эмпирических частотах (10 наблюдений в центральном интервале против 7 и 3 в краях), объединение интервалов размывает эти различия.

Результаты статистического моделирования (1000 итераций) количественно демонстрируют неработоспособность критерия Пирсона при малых объёмах выборок. Доля отвергнутых гипотез (мощность критерия) для равномерного распределения составляет всего 0.041, для распределения Лапласа — 0.086. Средние значения генерируемых статистик (0.950 и 1.282 соответственно) стабильно лежат значительно ниже критического порога 3.8415. Критерий обладает крайне низкой чувствительностью на выборках $n \leq 20$ и демонстрирует систематическое совершение ошибок второго рода.

Проведённый анализ иллюстрирует фундаментальное ограничение критерия χ^2 : требование минимальных ожидаемых частот $np_i \geq 5$ хотя и обеспечивает теоретическую сходимость к предельному распределению, но на практике приводит к чрезмерному объединению интервалов на малых выборках, что в свою очередь значительно снижает информативность критерия.

6 Выводы

При проверке нулевой гипотезы на выборке из нормального распределения ($n = 100$) критерий χ^2 Пирсона корректно определил генеральный закон с применением процедуры объединения интервалов. Вычисленная статистика $\chi_B^2 = 2.9944$ строго меньше критической квантили $\chi_{0.95}^2(3) = 7.8147$.

Анализ альтернативных законов на выборках малого объема ($n = 20$) выявил две взаимосвязанные проблемы. Во-первых, требование $np_i \geq 5$ приводит к необходимости объединения интервалов, что уменьшает чис-

ло степеней свободы с $c = 2$ до $c = 0$ (факт. $c = 1$). Во-вторых, даже после объединения критерий остается неработоспособным: для равномерного распределения $\chi_B^2 = 0.6573 \ll 3.8415$, для распределения Лапласа $\chi_B^2 = 3.4335 < 3.8415$.

Массовое статистическое моделирование (1000 итераций) подтвердило стойкое отсутствие мощности критерия при $n \leq 20$. Доля ошибочно отклоненных нормальных гипотез составила всего 4.1% для равномерного и 8.6% для лапласова распределения. Это свидетельствует о том, что критерий не способен различить совершенно не нормальные распределения на малых выборках.

Полученные результаты подчеркивают критическое значение этапа объединения интервалов с малыми ожидаемыми частотами и его негативное влияние на чувствительность критерия. Для надежного применения критерия хи-квадрат требуются выборки значительно большего объема (рекомендуется $n \geq 50$) или использование альтернативных тестов согласия (Колмогорова—Смирнова, Андерсона—Дарлинга), не требующих группировки данных.

7 Список литературы

- [1] Бабахина С. А., Баженов А. Н. Практикум по математической статистике: учеб. пособие. — СПб. : Санкт-Петербургский политехнический университет Петра Великого, 2026.
- [2] Максимов Ю. Д. Математика. Теория и практика по математической статистике. Конспект-справочник по теории вероятностей : учеб. пособие. — СПб. : Изд-во Политехн. ун-та, 2009. — 395 с.

8 Приложение

Исходный код программ доступен в репозитории на GitHub:
<https://github.com/Reichenau/math-stats-labs>